SAKARYA UYGULAMALI BİLİMLER ÜNİVERSİTESİ

Elektrik-Elektronik Mühendisliği Bölümü

FAZ 1: PROBLEM TANIMLAMA

Predictive Maintenance Using Machine Learning Techniques

Makine Öğrenmesi Teknikleri ile Tahmine Dayalı Bakım

Ders Kodu: EEF / Yapay Zekaya Giriş	**Proje Tipi:** Grup Projesi (En Fazla 2 Kişi)
Akademik Yıl: 2024 – 2025 Bahar Dönemi	**Faz:** Faz 1 – Problem Tanımlama

1. PROBLEMİN NET İFADESİ

1.1 Endüstriyel Bağlam ve Motivasyon

Modern üretim ve imalat tesislerinde makine ve ekipman arızaları, operasyonel sürdürülebilirlik açısından en kritik tehditlerden birini oluşturmaktadır. Beklenmedik makine duruşları, üretim hattı kesintilerine, stok kayıplarına ve ağır bakım maliyetlerine yol açmaktadır. Geleneksel periyodik bakım yaklaşımları ise ya gereğinden fazla bakım ile kaynak israfına ya da yetersiz bakım nedeniyle ani arızalara neden olmaktadır.

Tahmine Dayalı Bakım (Predictive Maintenance — PdM), makine öğrenmesi ve sensör verilerinin birleşimi aracılığıyla ekipman arızalarını gerçekleşmeden öngörmeyi hedefleyen veri odaklı bir mühendislik disiplinidir. Bu proje kapsamında; AI4I 2020 Predictive Maintenance Dataset üzerinde makine öğrenmesi algoritmaları uygulanarak beş farklı arıza tipi önceden tespit edilecek ve üretim sistemlerinin kesintisiz çalışmasına katkı sağlanacaktır.

1.2 Problem Tanımı

Bu projenin odaklandığı temel mühendislik problemi şu şekilde özetlenebilir:

"Bir endüstriyel makinenin hava sıcaklığı, süreç sıcaklığı, dönüş hızı, tork ve takım aşınması gibi gerçek zamanlı sensör ölçümlerinden yola çıkarak, makinenin yakın gelecekte arıza yapıp yapmayacağını ve hangi arıza tipine gireceğini yüksek doğrulukla tahmin edebilecek çok sınıflı bir makine öğrenmesi modeli geliştirmek."

1.3 Beklenmedik Arızaların Ekonomik ve Operasyonel Maliyeti

Endüstriyel arızaların maliyeti yalnızca maddi boyutla sınırlı kalmayıp çok katmanlı operasyonel etkiler doğurmaktadır:

- Duruş Süresi Maliyeti (Downtime Cost): Üretim hattında yaşanan plansız duruşlar, dakika başına on binlerce dolar kayba neden olabilmektedir. Aberdeen Group araştırmalarına göre üretim sektöründe plansız duruş maliyeti saatte ortalama 260.000 USD düzeyine ulaşmaktadır.
- Acil Tamir Masrafları: Planlı bakıma kıyasla acil onarım maliyetleri 3 ila 5 kat daha yüksek olabilmektedir. Yedek parça temini, öncelikli servis sözleşmeleri ve fazla mesai işçilik ücretleri bu maliyeti katlarına çıkarmaktadır.
- İkincil Hasar Riski: Arızaya uğrayan bir bileşen, zincirleme etkiyle bağlı diğer makinelerde de hasara yol açabilmekte; bu durum onarım kapsamını ve maliyetini önemli ölçüde büyütmektedir.
- İş Güvenliği Riskleri: Denetimsiz makine arızaları, operatörler için ciddi iş güvenliği tehlikeleri doğurabilmektedir.
- Müşteri Memnuniyeti ve Sözleşme Cezaları: Üretim aksaklıkları teslimat gecikmelerine, müşteri şikayetlerine ve sözleşmesel yaptırımlara yol açmaktadır.

Bu bağlamda tahmine dayalı bakım sistemlerinin etkin biçimde uygulanması; bakım maliyetlerini %10-25 oranında azaltabilmekte, ekipman kullanılabilirliğini %10-20 artırabilmekte ve acil arıza oranlarını %70'e kadar düşürebilmektedir (Deloitte Insights, 2019).

2. PAYDAŞ ANALİZİ

Predictive Maintenance sisteminin başarısı, yalnızca teknik doğruluğa değil; sistemin tasarımını, kullanımını ve sürdürülebilirliğini etkileyen çok sayıda paydaşın beklentilerini karşılamasına da bağlıdır.

Paydaş	Birincil Beklentiler	Başarı Göstergesi
Bakım Mühendisleri	Arızayı zamanında ve yanlış alarmsız tespit etmek; bakım planlamasını optimize etmek; gereksiz müdahaleyi azaltmak	Yüksek Recall (>0.90); Düşük Yanlış Alarm Oranı (FPR <0.15)
Fabrika Yöneticileri	Üretim sürekliliğini sağlamak; bakım maliyetlerini düşürmek; ROI'yi maksimize etmek; iş güvenliği standartlarını karşılamak	Planlı duruş süresi %30 azalma; Bakım maliyeti tasarrufu
Makine Operatörleri	Anlaşılır uyarılar almak; çalışan makineyi güvenli şekilde izlemek; gereksiz müdahale alarmından kurtulmak	Kullanıcı dostu arayüz; Açık alarm mesajları; Öncelik skoru görüntüleme
Veri / IT Ekibi	Sistemin mevcut SCADA/ERP altyapısına entegrasyonu; veri kalitesi ve güvenlik standartları	REST API desteği; Modüler kod; requirements.txt / Docker

3. BAŞARI METRİKLERİ

Bir tahmine dayalı bakım sisteminin değerlendirilmesinde yalnızca Accuracy (Doğruluk) metriği kullanmak, özellikle dengesiz (imbalanced) veri setlerinde yanıltıcı sonuçlar doğurabilir.

3.1 Neden Yalnızca Accuracy Yeterli Değil?

AI4I 2020 veri setinde makine arızası olayları toplam örneklerin yaklaşık %3.4'ünü oluşturmaktadır (10.000 satırda ~339 arıza vakası). Bu dengesiz sınıf dağılımı bağlamında, tüm örnekleri "arıza yok" olarak etiketleyen naif bir model bile %96.6 Accuracy elde edebilir. Oysa böyle bir model gerçekte hiçbir arızayı tespit etmemektedir; dolayısıyla operasyonel açıdan değersizdir.

3.2 Seçilen Metrikler ve Teknik Gerekçeleri

Bu proje kapsamında aşağıdaki dört performans metriği kullanılacaktır:

Metrik	Matematiksel Tanım	PdM Kapsamında Önemi	Hedef Eşik
Recall (Duyarlılık)	TP / (TP + FN)	Kaçırılan arızanın maliyeti yüksektir; FN minimuma indirilmeli	>= 0.90
Precision (Hassasiyet)	TP / (TP + FP)	Yanlış alarm bakım kaynağı israf eder; FP'nin de kontrol altında tutulması gerekir	>= 0.75
F1-Score	2 * (P * R) / (P + R)	Precision ve Recall arasındaki dengeyi tek metrikle ifade eder; sınıf imbalance durumunda güvenilir	>= 0.82
ROC-AUC	TPR / FPR eğrisi altı alan	Eşik değerinden bağımsız sınıflandırma gücünü gösterir; karşılaştırmalı analiz sağlar	>= 0.95

3.3 Maliyet-Duyarlı Değerlendirme Yaklaşımı

Tahmine dayalı bakım bağlamında hata maliyetleri simetrik değildir. Bir arızanın kaçırılması (False Negative), gereksiz bir bakım müdahalesi (False Positive) ile kıyaslandığında çok daha ağır sonuçlar doğurmaktadır. Bu asimetri göz önüne alındığında, eşik değeri optimizasyonunda Recall ağırlıklı F-beta (F2) skoru da hesaplanacak; nihai karar eşiği ROC eğrisi üzerinde optimum işletim noktası seçimi ile belirlenecektir.

4. PROJE KISITLARI

Projenin tasarımı ve geliştirme sürecinde aşağıdaki teknik ve metodolojik kısıtlar göz önünde bulundurulmuştur:

4.1 Verinin Sentetik Olması

AI4I 2020 veri seti, gerçek bir endüstriyel sistemden değil; mühendislik parametreleri esas alınarak sentetik olarak üretilmiş verilerden oluşmaktadır. Bu durum aşağıdaki sınırlılıkları beraberinde getirmektedir:

- Gerçek dünya gürültüsü (sensör bozulmaları, sinyal kayıpları, kalibrasyon hataları) veri setinde temsil edilmemektedir.
- Arıza koşulları matematiksel eşiklerle deterministik biçimde tanımlanmış olup, endüstriyel sistemlerde görülen stokastik arıza davranışlarını tam olarak yansıtmayabilir.
- Geliştirilen modelin gerçek üretim ortamlarına transferinde domain adaptation gereklilikleri doğabilecektir.

4.2 Veri Büyüklüğü Kısıtı

Veri seti 10.000 satır ile sınırlıdır. Bu büyüklük temel makine öğrenmesi modellerinin eğitimi için yeterli olmakla birlikte şu kısıtları doğurmaktadır:

- Derin öğrenme modellerinin yüksek kapasitelerinden tam anlamıyla yararlanmak için yetersiz kalabilmektedir.
- Nadir görülen arıza tipleri (örn. RNF — Rastgele Arıza) için eğitim örneği sayısı kritik alt sınırlara yaklaşmaktadır.
- Cross-validation bölünmelerinde istatistiksel anlamlılık sağlamak güçleşebilmektedir.

4.3 Sınıf Dengesizliği

Veri setindeki arıza örneklerinin oranı (~%3.4) ciddi sınıf dengesizliği (class imbalance) problemi yaratmaktadır. Bu kısıtı aşmak amacıyla SMOTE (Synthetic Minority Over-sampling Technique), sınıf ağırlıklandırma ve eşik optimizasyonu gibi yöntemler değerlendirilecektir.

4.4 Hesaplama Kaynakları

Proje Google Colab ücretsiz katmanı veya yerel geliştirme ortamında yürütüleceğinden GPU kısıtları nedeniyle büyük ölçekli hiperparametre arama uzayları sınırlandırılabilecektir. Bu nedenle Random Search ve Bayesian Optimization gibi verimli arama stratejileri tercih edilecektir.

4.5 Açıklanabilirlik Gerekliliği

Endüstriyel uygulamalarda bakım mühendisleri, modelin neden belirli bir arıza tahmini ürettiğini anlamak istemektedir. Bu gereklilik yalnızca yüksek performanslı değil; aynı zamanda yorumlanabilir ve açıklanabilir modellerin tercih edilmesini zorunlu kılmaktadır. SHAP ve LIME yöntemlerinin entegrasyonu bu kısıtın karşılanması için planlanmaktadır.

5. LİTERATÜR ÖZETİ

Tahmine dayalı bakım alanında makine öğrenmesi uygulamalarına yönelik kapsamlı bir literatür taraması gerçekleştirilmiştir. Temel bulgular aşağıda özetlenmektedir:

- Mobley (2002) geleneksel periyodik bakımın yetersizliklerini ve koşula dayalı bakım (Condition-Based Maintenance) paradigmasına geçişin ekonomik faydalarını kapsamlı biçimde ortaya koymuştur.
- Peng ve ark. (2019) veri güdümlü PdM yaklaşımlarının CMAPSS ve benzeri endüstriyel veri setleri üzerindeki başarısını LSTM ve CNN mimarileriyle göstermiştir.
- AI4I 2020 veri setini tanıtan Matzka (2020), sentetik endüstriyel veri üretiminin gerçekçilik kriterlerini ve veri setinin sınıflandırma zorluklarını belgelemiştir.
- Deloitte Insights (2019) PdM sistemlerinin endüstri 4.0 bağlamındaki ROI analizini gerçekleştirmiş; ortalama %25 bakım maliyeti düşüşü ve %10-20 ekipman kullanılabilirlik artışı raporlanmıştır.

Faz 1 raporu tamamlanmıştır. Sıradaki adım: Faz 2 – Veri Toplama & Etiketleme