SAKARYA UYGULAMALI BİLİMLER ÜNİVERSİTESİ

Elektrik-Elektronik Mühendisliği Bölümü

FAZ 2: VERİ TOPLAMA & ETİKETLEME

Predictive Maintenance Using Machine Learning Techniques

Makine Öğrenmesi Teknikleri ile Tahmine Dayalı Bakım

Ders Kodu: EEF / Yapay Zekaya Giriş	**Proje Tipi:** Grup Projesi (En Fazla 2 Kişi)
Akademik Yıl: 2024 – 2025 Bahar Dönemi	**Faz:** Faz 2 – Veri Toplama & Etiketleme
Veri Seti: AI4I 2020 Predictive Maintenance Dataset	**Metodoloji:** CRISP-DM & MLOps Standartları

1. VERİ KAYNAĞI

1.1 Veri Setinin Kimliği ve Kaynağı

Bu projede kullanılan AI4I 2020 Predictive Maintenance Dataset, endüstriyel makine sistemlerinin tahmine dayalı bakım problemleri için özel olarak tasarlanmış kapsamlı bir sentetik veri kümesidir. Stephan Matzka tarafından 2020 yılında hazırlanmış ve UCI Machine Learning Repository üzerinde yayımlanmıştır. Erişim Kaggle platformu üzerinden sağlanmaktadır.

Özellik	Açıklama
Veri Seti Adı	AI4I 2020 Predictive Maintenance Dataset
Yazar / Kaynakçı	Stephan Matzka (TH Bergisch Gladbach)
Birincil Depo	UCI Machine Learning Repository (DOI: 10.24432/C5HS5K)
Kaggle Erişim	kaggle.com/datasets/stephanmatzka/predictive-maintenance-dataset-ai4i-2020
Yayın Yılı	2020
Lisans Türü	CC BY 4.0 (Creative Commons Attribution)
Satır Sayısı	10.000
Sütun Sayısı	14 (6 giriş özelliği + 6 arıza etiketi + 2 kimlik)
Veri Türü	Sentetik Endüstriyel Sensör Verisi

1.2 Verinin Temin Edilmesi

Veri seti Kaggle platformu üzerinden CSV formatında indirilmiştir. İndirilen dosya (predictive_maintenance.csv) projenin GitHub deposundaki /data/raw/ klasörüne yerleştirilmiş ve orijinal ham haliyle versiyon kontrolüne eklenmiştir. Kaggle API üzerinden otomatik indirme için şu komut kullanılabilir:

```
kaggle datasets download -d stephanmatzka/predictive-maintenance-dataset-ai4i-2020
```

2. VERİ SÖZLÜĞÜ (DATA DICTIONARY)

2.1 Giriş Özellikleri (Input Features)

Veri setindeki her satır, bir endüstriyel makinenin tek bir zaman dilimindeki operasyonel ölçümünü temsil etmektedir. Aşağıdaki tabloda tüm giriş özellikleri tanımlanmaktadır:

Sütun Adı	Tam Adı	Veri Tipi	Değer Aralığı	Mühendislik Açıklaması
`Type`	Machine Type (Makine Türü)	Kategorik (str)	L / M / H	Makinenin kalite sınıfını temsil eder. L: Düşük kalite (%60), M: Orta kalite (%30), H: Yüksek kalite (%10). Kalite sınıfı sıcaklık sapmasını belirler.
`Air temperature [K]`	Hava Sıcaklığı	Sürekli (float)	295.3 – 304.5 K	Makinenin çevresindeki ortam hava sıcaklığı. Kelvin cinsinden ölçülmekte; normal dağılım etrafında ~300 K'de seyreder.
`Process temperature [K]`	Süreç Sıcaklığı	Sürekli (float)	305.7 – 313.8 K	Üretim sürecinin iç sıcaklığı. Genellikle Hava Sıcaklığı + 10 K civarında seyreder; aşırı yükte artış arıza riskini yükseltir.
`Rotational speed [rpm]`	Dönüş Hızı	Sürekli (int)	1168 – 2886 rpm	Makine milinin dakikadaki devir sayısı. 2860 W'lik güçle normal dağılımdan üretilmiş; düşük hızlar PWF riskini artırır.
`Torque [Nm]`	Tork	Sürekli (float)	3.8 – 76.6 Nm	Makine miline uygulanan dönüş kuvveti. Normal dağılımla üretilmiş (ort. ~40 Nm); dönüş hızı ile negatif korelasyon gösterir.
`Tool wear [min]`	Takım Aşınması	Sürekli (int)	0 – 253 dk	Kesici takımın toplam kullanım süresi. H tipinde 5 dk/adet, M ve L tiplerinde 3 dk/adet artış gösterir. Yüksek aşınma TWF riskini tetikler.

2.2 Type Özelliğinin Detaylandırılması

Type özelliği üç farklı kalite düzeyini kodlamaktadır:

- L (Low Quality — Düşük Kalite): Veri setinin %60'ını oluşturur. Süreç sıcaklığı ile hava sıcaklığı arasındaki fark H sınıfına kıyasla daha yüksektir.
- M (Medium Quality — Orta Kalite): Veri setinin %30'unu oluşturur. Takım aşınma hızı 3 dakika/birim olarak ayarlanmıştır.
- H (High Quality — Yüksek Kalite): Veri setinin %10'unu oluşturur. Takım aşınma hızı 5 dakika/birim; bu makinelerin daha ağır koşullarda çalıştığı simüle edilmiştir.

3. HEDEF DEĞİŞKEN (TARGET VARIABLE)

3.1 Machine Failure — Birincil Hedef

Machine Failure (0/1), veri setinin birincil ikili sınıflandırma hedef değişkenidir. 0 değeri makinenin normal çalıştığını, 1 değeri ise herhangi bir arıza modunun etkin olduğunu göstermektedir. Veri setindeki ~339 arıza vakası toplam örneklerin yaklaşık %3.4'üne karşılık gelmekte olup ciddi bir sınıf dengesizliği söz konusudur.

3.2 Arıza Alt Tipleri (Failure Mode Labels)

Machine Failure ana etiketine ek olarak beş farklı arıza modu etiketi bulunmaktadır. Her etiket ikili (0/1) yapıdadır ve belirli mühendislik koşulları altında otomatik olarak atanmıştır:

Kod	Tam Adı	Tetiklenme Koşulu	Mühendislik Açıklaması	Vaka Sayısı
TWF	Tool Wear Failure (Takım Aşınma Arızası)	Takım aşınması 200-240 dk aralığına ulaştığında	Aşının limit değerini geçmesi sonucu takımın kırılması veya işlevini yitirmesi.	~46 vaka
HDF	Heat Dissipation Failure (Isı Dağıtım Arızası)	Hava-süreç sıcaklık farkı < 8.6 K VE dönüş hızı < 1380 rpm	Yetersiz soğutma + düşük hızın birleşimi makineyi aşırı ısınmaya sürmektedir.	~115 vaka
PWF	Power Failure (Güç Arızası)	Tork × Dönüş hızı (rad/s) < 3500 W veya > 9000 W	Güvenli çalışma aralığının dışına çıkış; alt sınırda yetersiz güç, üst sınırda aşırı yüklenme.	~95 vaka
OSF	Overstrain Failure (Aşırı Yük Arızası)	Takım aşınması × Tork, L/M/H sınıfına göre belirlenen eşiği aşarsa	Düşük kaliteli makinelerde aşırı mekanik stres birikimiyle ortaya çıkan yorulma arızası.	~98 vaka
RNF	Random Failure (Rastgele Arıza)	Her örnekte %0.1 ihtimalle rastgele tetiklenir	Hiçbir mühendislik parametresiyle açıklanamayan stokastik arıza modu.	~19 vaka

4. ETİKETLEME STRATEJİSİ

4.1 Çok Sınıflı Sınıflandırma Yaklaşımı

Bu proje, basit bir ikili sınıflandırma (arıza var / yok) yaklaşımının ötesine geçerek her bir arıza tipini bağımsız olarak öngörmeyi hedefleyen Çoklu Etiket Sınıflandırması (Multi-Label Classification) ve Çok Sınıflı Sınıflandırma (Multiclass Classification) stratejilerini uygulamaktadır.

Bu yaklaşımın temel motivasyonu şu mühendislik gerçekliğinden kaynaklanmaktadır: Bakım mühendisine yalnızca "makine arızalanacak" demek yeterli değildir. Arıza tipinin önceden bilinmesi, müdahale stratejisini kökten değiştirir:

- TWF tespit edilirse: Takım değişim zamanlaması optimize edilir; acil stok ikmalı yapılır.
- HDF tespit edilirse: Soğutma sistemi incelenir; hava akışı ve fan verimliliği kontrol edilir.
- PWF tespit edilirse: Güç beslemesi ve motor parametreleri denetlenir; aşırı yük koşulları araştırılır.
- OSF tespit edilirse: Makine yük programı gözden geçirilir; periyodik tork kalibrasyonu yapılır.
- RNF tespit edilirse: Genel sistem denetimi başlatılır; olası dış etkenler araştırılır.

4.2 Etiketleme Modelleri

Etiketleme Modu	Açıklama	Kullanılacak Algoritmalar
İkili Sınıflandırma (Binary)	Machine Failure (0/1) tahmini. Temel model olarak kullanılır; Faz 4 baseline karşılaştırmasında referans olacaktır.	Logistic Regression, Random Forest, XGBoost, SVM
Çok Etiketli Sınıflandırma (Multi-Label)	Her arıza tipi (TWF, HDF, PWF, OSF, RNF) için ayrı birer ikili sınıflandırıcı. Herhangi biri aktifse Machine Failure = 1 kabul edilir.	OneVsRest Classifier, MultiOutputClassifier, DNN çoklu çıkış katmanı

4.3 Veri Bölme Stratejisi

Modelin genellenebilirliğini güvence altına almak amacıyla veri seti aşağıdaki oranlarda bölünecektir:

- Eğitim Seti (%70 — 7.000 satır): Model parametrelerinin öğrenilmesinde kullanılır.
- Doğrulama Seti (%15 — 1.500 satır): Hiperparametre optimizasyonu ve erken durdurma kararlarında kullanılır.
- Test Seti (%15 — 1.500 satır): Nihai model performansının raporlanmasında kullanılır; bu set yalnızca son değerlendirmede görülür.

Sınıf dengesizliği nedeniyle bölme işlemi stratified sampling yöntemiyle gerçekleştirilecek; böylece her üç kümedeki arıza oranının (~%3.4) korunması sağlanacaktır.

4.4 Sınıf Dengesizliğine Yönelik Teknikler

- SMOTE (Synthetic Minority Over-sampling Technique): Azınlık sınıfından yapay sentetik örnekler üretilerek dengesizlik giderilecektir.
- Class Weight Adjustment: Azınlık sınıfına daha yüksek ağırlık atanarak hata fonksiyonunda arıza örnekleri önceliklendirilecektir.
- Threshold Tuning: Tahmin eşiği optimize edilerek Recall-Precision dengesi operasyonel gereklilik doğrultusunda ayarlanacaktır.

5. VERİ ENVANTERİ

Dosya / Kaynak	Format	Boyut	Repo Konumu
`predictive_maintenance.csv`	CSV	10.000 satır × 14 sütun	/data/raw/
`Kaggle Dataset (UCI kaynaklı)`	ZIP/CSV	~444 KB	Kaggle Downloads
`cleaned_data.csv (Faz 3 sonrası)`	CSV	~10.000 satır × 12 sütun	/data/processed/
`train.csv`	CSV	7.000 satır	/data/splits/
`val.csv`	CSV	1.500 satır	/data/splits/
`test.csv`	CSV	1.500 satır	/data/splits/

Faz 2 raporu tamamlanmıştır. Sıradaki adım: Faz 3 – Keşifsel Veri Analizi (EDA)